Universidad de los Andes
Programa Ciencia de Datos
Aplicaciones en Ciencia de Datos (DATA-1002)
Profesores: Nicolas Mejia Martinez, Nicolas Felipe Suarez Ariza

Laboratorio 3: Estructura Tabular

Con relación al desarrollo y entrega del taller, tenga en cuenta lo siguiente:

- El desarrollo del taller se debe llevar a cabo en grupos de máximo 3 personas.
- El uso de herramientas de inteligencia generativa durante el desarrollo del taller está estrictamente prohibido.
- La solución del taller debe ser subido al link disponible en bloque neón antes del fin de clase.
- Todo el taller debe desarrollarse en un único archivo .ipynb que deberá tener el código pedido y la respuesta a cada una de las preguntas del taller.
- No se calificarán envíos posteriores a esta fecha y hora.
- Cualquier sospecha de fraude será manejada de acuerdo con el reglamento de la Universidad.

AndesWell

La Dirección de Bienestar Universitario ha realizado una encuesta institucional con el propósito de comprender mejor algunos factores que podrían estar relacionados con el desempeño académico y la experiencia universitaria de sus estudiantes.

La encuesta recoge información demográfica, hábitos de estudio, calidad del sueño, niveles de estrés, actividad física, uso de herramientas de Inteligencia Artificial, modalidad de estudio y percepción general de la vida universitaria. La información será utilizada para identificar oportunidades de mejora en programas de acompañamiento académico y bienestar.

Sin embargo, antes de responder cualquier pregunta de investigación, el equipo de Ciencia de Datos necesita entender la estructura y la calidad de la información disponible.

Ustedes han sido contratados como científicos de datos y su primera tarea consiste en realizar un diagnóstico inicial del conjunto de datos para determinar si está listo para ser utilizado en un proyecto de analítica. Para esto deberán:

1. Carguen el archivo *estudiantes.csv* a su ambiente de trabajo, luego realicen una inspección inicial. Incluyan como mínimo evidencia de:

   - Primeras y últimas filas.
   - Dimensiones del dataset.
   - Nombres de las columnas.
   - Tipos de datos inferidos por Pandas.

   Adicionalmente, respondan en Markdown:

   a. ¿Qué representa una fila del dataset?
   b. ¿Cuál es la unidad de análisis?
   c. ¿Cuántas observaciones y variables hay?
   d. ¿Qué parece representar el dataset en términos del problema o dominio?

2. Construyan un diccionario para todas las variables del dataset. Si el significado de una variable no puede determinarse con seguridad, indíquenlo explícitamente como una duda en lugar de inventar una definición.

Variable	Tipo en Python	Escala	Descripción	Ejemplo	Observaciones
cliente_id	object	Nominal	Identificador del cliente	C001	Debe ser único

3. Realicen un diagnóstico inicial de calidad del dataset, usando el siguiente cuadro como guía:

Aspecto	Pregunta guía
Dimensiones	¿Qué tan grande es el dataset?
Tipos	¿Los tipos inferidos tienen sentido?
Faltantes	¿Dónde se concentran los valores ausentes?
Duplicados	¿Existen filas repetidas?
Cardinalidad	¿Cuántos valores distintos tiene cada variable?
Distribución	¿Qué rangos, categorías o valores llaman la atención?

4. ¿Hay columnas cuyo significado o nombre no sea suficientemente claro?
5. ¿Existen códigos, categorías o unidades que requerirían documentación adicional?
6. ¿Hay variables cuyo tipo en Python no corresponda con su significado analítico?
7. ¿Detectan categorías inconsistentes, rangos improbables o posibles errores de captura?
8. ¿Qué información adicional pedirían al dueño de los datos antes de analizar?

9. ¿Qué riesgos tendría comenzar un análisis sin resolver estas dudas?

10. Propongan 3 preguntas analíticas que podrían investigarse con este dataset. Para cada una, indiquen qué variables utilizarían y si consideran que los datos actuales son suficientes para responderla.

Pregunta analítica	Variables necesarias	¿Datos suficientes? ¿Por qué?

11. Escriba una conclusión de entre 150 y 200 palabras dirigida a otro analista que recibirá el proyecto. Debe contener como mínimo:

    a. ¿Qué contiene el dataset?

    b. ¿Qué tan utilizable parece en su estado actual?

    c. ¿Cuáles son los principales problemas o incertidumbres?

    d. ¿Cuáles deberían ser los siguientes pasos?